深度学习之卷积神经网络CNN及tensorflow代码实现示例

2017年05月01日 13:28:21 标签：深度学习 / Batch-Norm / 卷积神经网络cnn 50243

一、CNN的引入

在人工的全连接神经网络中，每相邻两层之间的每个神经元之间都是有边相连的。当输入层的特征维度变得很高时，这时全连接网络需要训练的参数就会增大很多，计算速度就会变得很慢，例如一张黑白的 28×28 的手写数字图片，输入层的神经元就有784个，如下图所示：

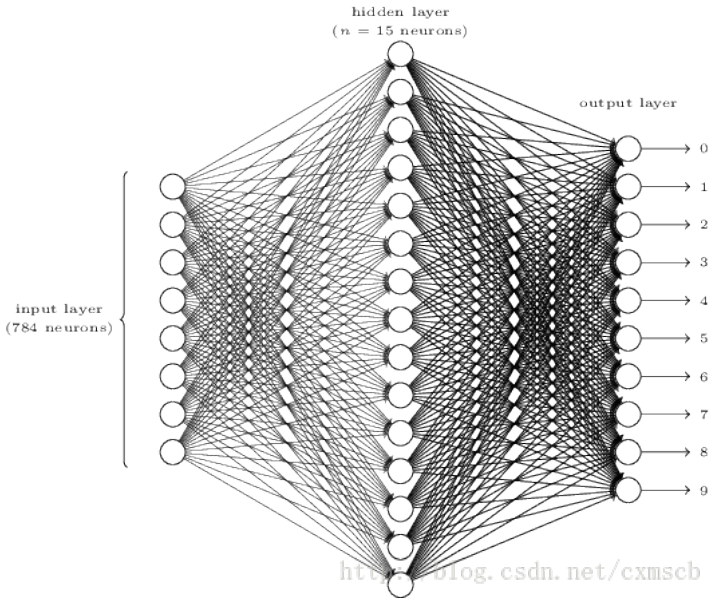

若在中间只使用一层隐藏层，参数 w 就有 $784 \times 15 = 11760$ 多个；若输入的是28×28 带有颜色的RGB格式的手写数字图片，输入神经元就有$28 \times 28 \times 3 = 2352$ 个..... 。这很容易看出使用全连接神经网络处理图像中的需要训练参数过多的问题。

而在卷积神经网络（Convolutional Neural Network,CNN）中，卷积层的神经元只与前一层的部分神经元节点相连，即它的神经元间的连接是非全连接的，且同一层中某些神经元之间的连接的权重 w 和偏移 b 是共享的（即相同的），这样大量地减少了需要训练参数的数量。

卷积神经网络CNN的结构一般包含这几个层：

- 输入层：用于数据的输入
- 卷积层：使用**卷积核**进行特征提取和特征映射
- 激励层：由于卷积也是一种线性运算，因此需要增加非线性映射
- 池化层：进行下采样，对特征图稀疏处理，减少数据运算量。
- 全连接层：通常在CNN的尾部进行重新拟合，减少特征信息的损失
- 输出层：用于输出结果

当然中间还可以使用一些其他的功能层:

- 归一化层（Batch Normalization）：在CNN中对特征的归一化
- 切分层：对某些（图片）数据的进行分区域的单独学习
- 融合层：对独立进行特征学习的分支进行融合

二、CNN的层次结构

cxmscb

原创 83 粉丝 208 喜欢 86 评论 81

等级： 博客 5 访问量： 29万+

积分： 2972 排名： 1万+

输入层：

在CNN的输入层中，（图片）数据输入的格式 与 全连接神经网络的输入格式（一维向量）不太一样。CNN的输入层的输入格式保留了图片本身的结构。

对于黑白的 28×28 的图片，CNN的输入是一个 28×28 的的二维神经元，如下图所示：

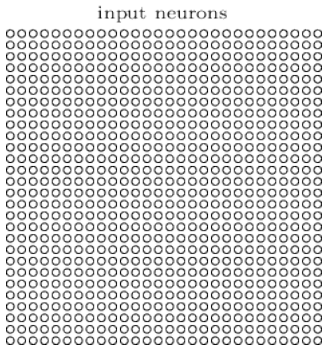

而对于RGB格式的28×28图片，CNN的输入则是一个 $3 \times 28 \times 28$ 的三维神经元（RGB中的每一个颜色通道都有一个 28×28 的矩阵），如下图所示：

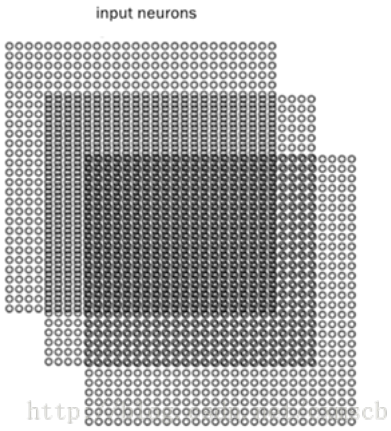

卷积层：

在卷积层中有几个重要的概念：

- local receptive fields（感受视野）
- shared weights（共享权值）

假设输入的是一个 28×28 的的二维神经元，我们定义5×5 的 一个 local receptive fields（感受视野），即隐藏层的神经元与输入层的5×5个神经元相连，这个5*5的区域就称之为Local Receptive Fields，如下图所示：

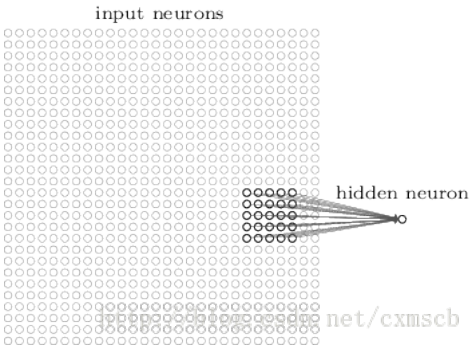

可类似看作：隐藏层中的神经元 具有一个固定大小的感受视野去感受上一层的部分特征。在全连接神经网络中，隐藏层中的神经元的感受视野足够大乃至可以看到上一层的所有特征。

而在卷积神经网络中，隐藏层中的神经元的感受视野比较小，只能看到上一次的部分特征，上一层的其他特征可以通过平移感受视野来得到同一层的其他神经元，由同一层其他神经元来看：

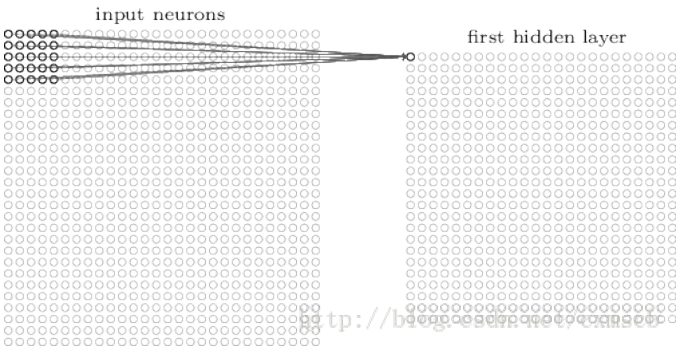

设移动的步长为1：从左到右扫描，每次移动 1 格，扫描完之后，再向下移动一格，再次从左到右扫描。

具体过程如动图所示：

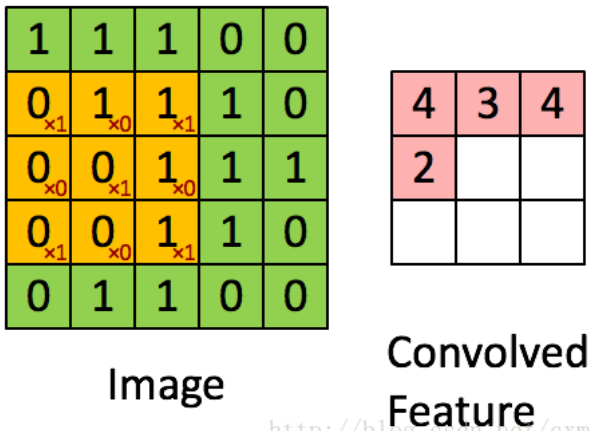

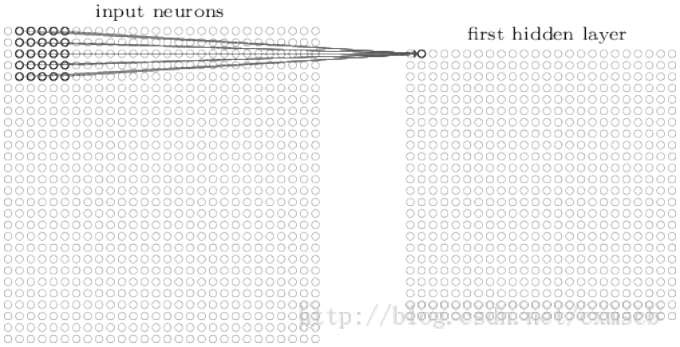

可看出 卷积层的神经元是只与前一层的部分神经元节点相连，每一条相连的线对应一个权重 w 。

一个感受视野带有一个卷积核，我们将 感受视野 中的权重 w 矩阵称为 **卷积核** ； 将感受视野对输入的扫描间隔称为**步长（stride）**；当步长比较大时（stride>1），为了扫描到边缘的一些特征，感受视野可能会“出界”，这时需要对**边界扩充(pad)**，边界扩充可以设为 0 或 其他值。步长 和 边界扩充值的大小由用户来定义。

卷积核的大小由用户来定义，即定义的感受视野的大小；卷积核的权重矩阵的值，便是卷积神经网络的参数，为了有一个偏移项 ，卷积核可附带一个偏移项 b ，它们的初值可以随机来生成，可通过训练进行变化。

因此 感受视野 扫描时可以计算出下一层神经元的值为：

$$b + \sum_{i=0}^{4} \sum_{j=0}^{4} w_{ij} x_{ij}$$

对下一层的所有神经元来说，它们从不同的位置去探测了上一层神经元的特征。

我们将通过 一个带有**卷积核**的**感受视野** 扫描生成的下一层神经元矩阵 称为 一个**feature map (特征映射图)**，如下图的右边便是一个 feature map：

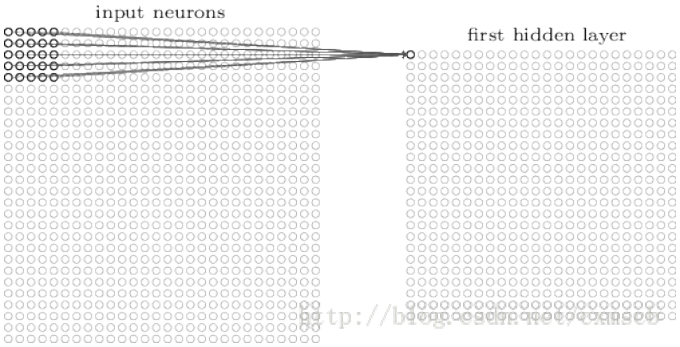

因此在同一个 **feature map** 上的神经元使用的卷积核是相同的，因此这些神经元 shared weights，共享卷积核中的权值和附带的偏移。一个 feature map 对应 一个卷积核，若我们使用 3 个不同的卷积核，可以输出3个feature map：（感受视野：5×5，布长stride：1）

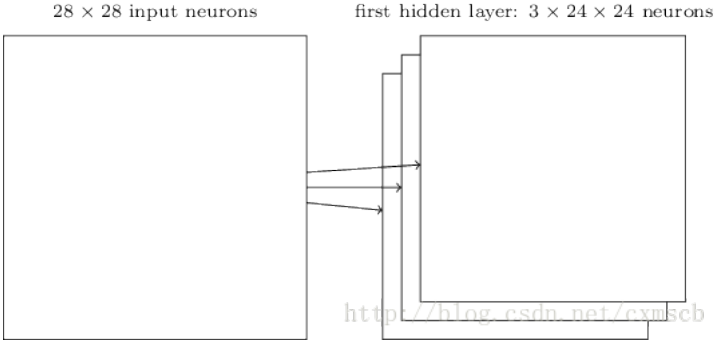

因此在CNN的卷积层，我们需要训练的参数大大地减少到了 $(5 \times 5 + 1) \times 3 = 78$个。

假设输入的是 28×28 的RGB图片，即输入的是一个 $3 \times 28 \times 28$ 的的二维神经元，这时卷积核的大小不只用长和宽来表示，还有深度，感受视野也对应的有了深度，如下图所示：

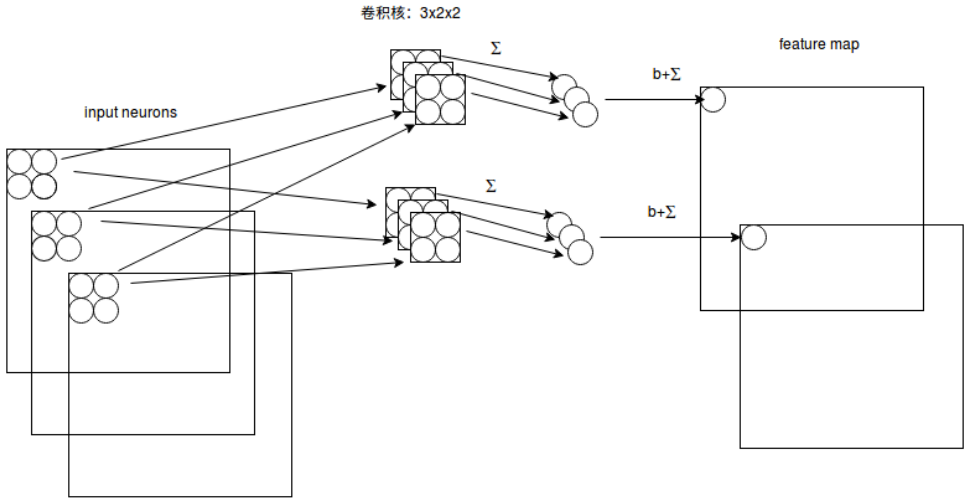

由图可知：感受视野： $3 \times 2 \times 2$ ； 卷积核： $3 \times 2 \times 2$ ，深度为3；下一层的神经元的值为： $b + \sum_{d=0}^{2} \sum_{i=0}^{1} \sum_{j=0}^{1} w_{dij} x_{dij}$. 卷积核的深度和感受视野的深度相同，都由输入数据来决定，长宽可由自己来设定，数目也可以由自己来设定，**一个卷积核依然对应一个 feature map** 。

注：“$stride = 1$”表示在长和宽上的移动间隔都为1，即 $stride_{width} = 1$ 且 $stride_{height} = 1$

激励层：

激励层主要对卷积层的输出进行一个非线性映射，因为卷积层的计算还是一种线性计算。使用的激励函数一般为ReLu函数：

$$f(x) = max(x, 0)$$

卷积层和激励层通常合并在一起称为“卷积层”。

池化层：

当输入经过卷积层时，若感受视野比较小，布长stride比较小，得到的feature map （特征图）还是比较大，可以通过池化层来对每一个 feature map 进行降维操作，输出的深度还是不变的，依然为 feature map 的个数。

池化层也有一个“池化视野（filter）”来对feature map矩阵进行扫描，对“池化视野”中的矩阵值进行计算，一般有两种计算方式：

- Max pooling：取“池化视野”矩阵中的最大值
- Average pooling：取“池化视野”矩阵中的平均值

扫描的过程中同样地会涉及的扫描布长stride，扫描方式同卷积层一样，先从左到右扫描，结束则向下移动布长大小，再从左到右。如下图示例所示：

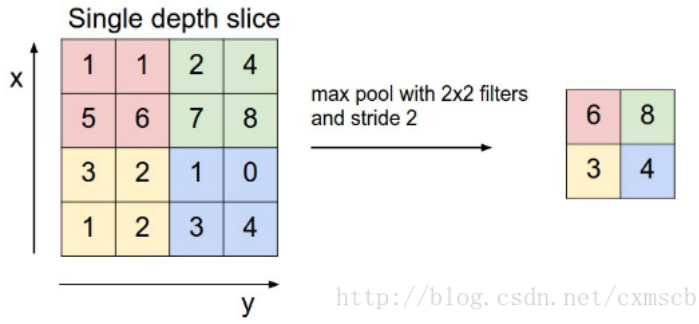

其中“池化视野”filter： 2×2；布长stride：2。（注：“ 池化视野”为个人叫法）

最后可将 3 个 24×24 的 feature map 下采样得到 3 个 24×24 的特征矩阵：

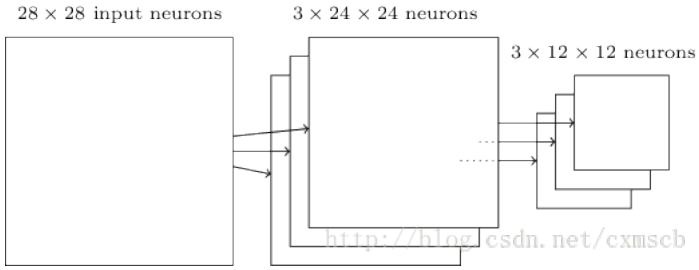

归一化层：

1. Batch Normalization

Batch Normalization（批量归一化）实现了在神经网络层的中间进行预处理的操作，即在上一层的输入归一化处理后再进入网络的下一层，这样可有效地防止“梯度弥散”，加速网络训练。

Batch Normalization具体的算法如下图所示：

Input: Values of x over a mini-batch: $\mathcal{B} = \{x_{1...m}\}$;
Parameters to be learned: γ, β
Output: $\{y_i = \mathrm{BN}_{\gamma,\beta}(x_i)\}$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m}\sum_{i=1}^{m} x_i \qquad \text{// mini-batch mean}$$

$$\sigma_{\mathcal{B}}^2 \leftarrow \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2 \qquad \text{// mini-batch variance}$$

$$\widehat{x}_i \leftarrow \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}} \qquad \text{// normalize}$$

$$y_i \leftarrow \gamma \widehat{x}_i + \beta \equiv \mathrm{BN}_{\gamma,\beta}(x_i) \qquad \text{// scale and shift}$$

每次训练时，取 batch_size 大小的样本进行训练，在BN层中，将一个神经元看作一个特征，batch_size 个样本在某个特征维度会有 batch_size 个值，然后在每个神经元 x_i 维度上的进行这些样本的均值和方差，通过公式得到 $\hat{x_i}$，再通过参数 γ 和 β 进行线性映射得到每个神经元对应的输出 y_i 。在BN层中，可以看出每一个神经元维度上，都会有一个参数 γ 和 β ，它们同权重w一样可以通过训练进行优化。

在卷积神经网络中进行批量归一化时，一般对 未进行ReLu激活的 feature map进行批量归一化，输出后再作为激励层的输入，可达到调整激励函数偏导的作用。

一种做法是将 feature map 中的神经元作为特征维度，参数 γ 和 β 的数量和则等于 $2 \times fmap_{width} \times fmap_{length} \times fmap_{num}$，这样做的话参数的数量会变得很多；

另一种做法是把 一个 feature map 看做一个特征维度，一个 feature map 上的神经元共享这个 feature map的参数 γ 和 β ，参数 γ 和 β 的数量和则等于 $2 \times fmap_{num}$，计算均值和方差则在batch_size个训练样本在每一个feature map维度上的均值和方差。

注：$fmap_{num}$指的是一个样本的feature map数量，feature map 跟神经元一样也有一定的排列顺序。

Batch Normalization 算法的训练过程和测试过程的区别：

在训练过程中，我们每次都会将 batch_size 数目大小的训练样本 放入到CNN网络中进行训练，在BN层中自然可以得到计算输出所需要的 **均值** 和 **方差**；

而在测试过程中，我们往往只会向CNN网络中输入一个测试样本，这是在BN层计算的均值和方差会均为 **0**，因为只有一个样本输入，因此BN层的输入也会出现很大的问题，从而导致CNN网络输出的错误。所以在测试过程中，我们需要借助训练集中所有样本在BN层归一化时每个维度上的均值和方差，当然为了计算方便，我们可以在 batch_num 次训练过程中，将每一次在BN层归一化时每个维度上的均值和方差进行相加，最后再进行求一次均值即可。

2. Local Response Normalization

近邻归一化(Local Response Normalization)的归一化方法主要发生在不同的相邻的卷积核（经过ReLu之后）的输出之间，即输入是发生在不同的经过ReLu之后的 feature map 中。

LRN的公式如下：

$$b(i,x,y) = \frac{a(i,x,y)}{(k + \alpha \sum_{j=max(0,i-n/2)}^{min(N-1,i+n/2)} a(j,x,y)^2)^{\beta}}$$

其中：
$a(i,x,y)$ 表示第i个卷积核的输出（经过ReLu层）的feature map上的 $(x，y)$ 位置上的值。
$b(i,x,y)$ 表示 $a(i,x,y)$ 经LRN后的输出。
N 表示卷积核的数量，即输入的 feature map的个数。
n 表示近邻的卷积核（或feature map）个数，由自己来决定。
k, α, β是超参数，由用户自己调整或决定。

与BN的区别：BN依据mini batch的数据,近邻归一仅需要自己来决定，BN训练中有学习参数;BN归一化主要发生在不同的样本之间，LRN归一化主要发生在不同的卷积核的输出之间。

切分层：

在一些应用中,需要对图片进行切割，独立地对某一部分区域进行单独学习。这样可以对特定部分进行通过调整 **感受视野** 进行力度更大的学习。

融合层：

融合层可以对切分层进行融合，也可以对不同大小的卷积核学习到的特征进行融合。

例如在GoogleLeNet 中，使用多种分辨率的卷积核对目标特征进行学习，通过 **padding** 使得每一个 **feature map** 的长宽都一致，之后再将多个 feature map 在深度上拼接在一起：

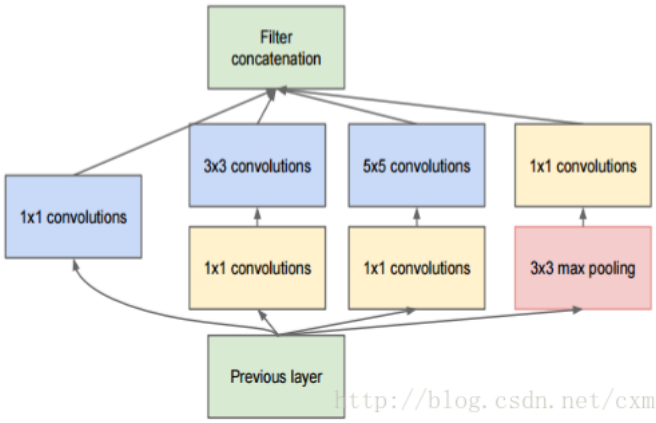

全连接层和输出层

全连接层主要对特征进行重新拟合，减少特征信息的丢失；输出层主要准备做好最后目标结果的输出。例如VGG的结构图，如下图所示：

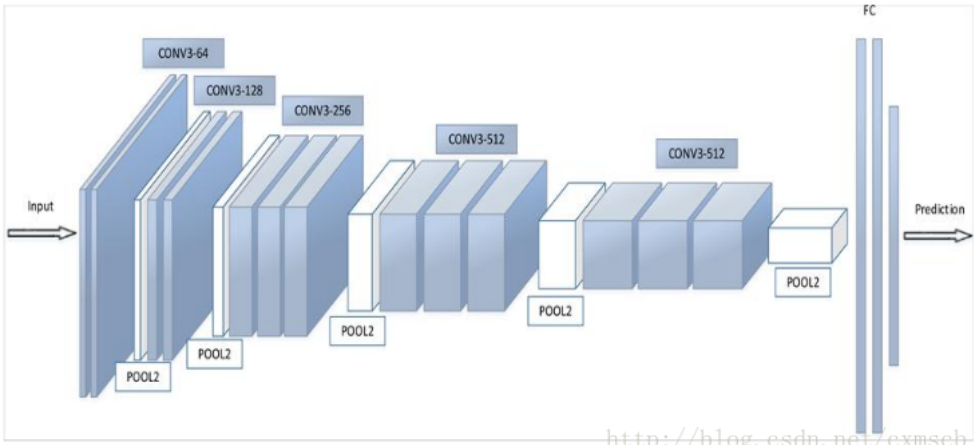

典型的卷积神经网络

LeNet-5模型

第一个成功应用于数字数字识别的卷积神经网络模型（卷积层自带激励函数，下同）：

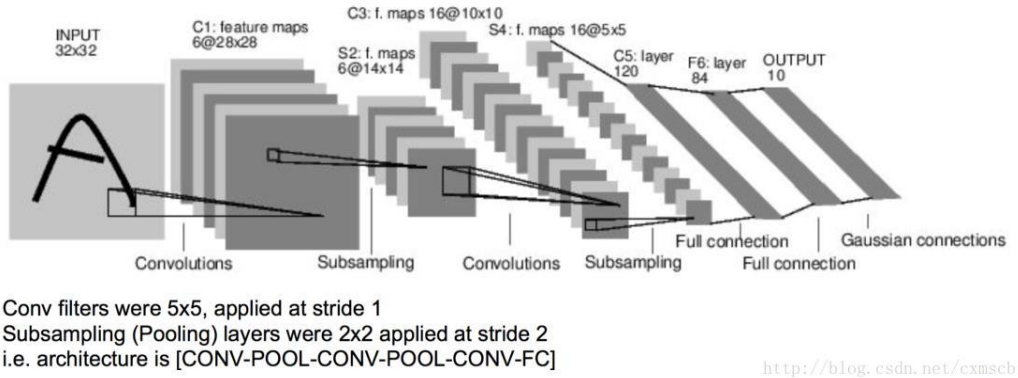

Conv filters were 5x5, applied at stride 1
Subsampling (Pooling) layers were 2x2 applied at stride 2
i.e. architecture is [CONV-POOL-CONV-POOL-CONV-FC]

卷积层的卷积核边长都是5，步长都为1；池化层的窗口边长都为2，步长都为2。

AlexNet 模型

具体结构图：

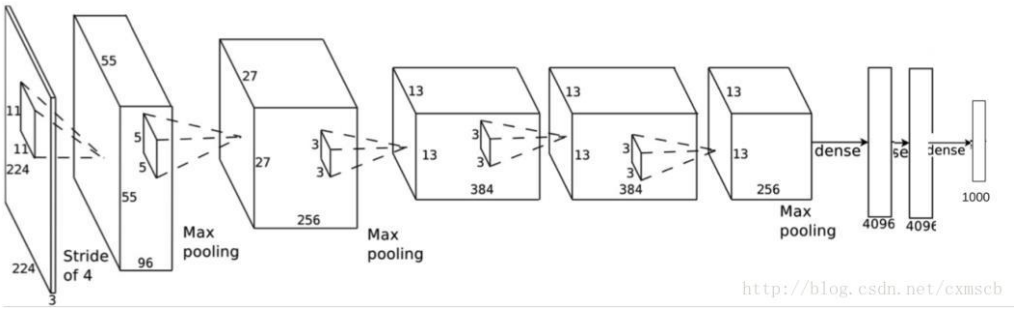

从AlexNet的结构可发现：经典的卷积神经网络结构通常为：

输入层 → (卷积层+ → 池化层？)+ → 全连接层+ → 输出层

AlexNet卷积层的卷积核边长为5或3，池化层的窗口边长为3。具体参数如图所示：

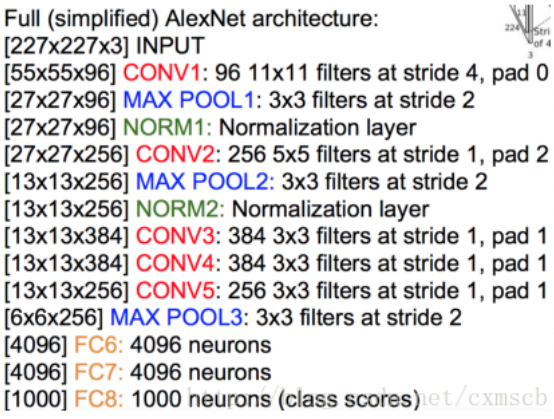

VGGNet 模型

VGGNet 模型 和 AlexNet模型 在结构上没多大变化，在卷积层部位增加了多个卷积层。AlexNet（上） 和 VGG Net （下）的对比如下图所示：

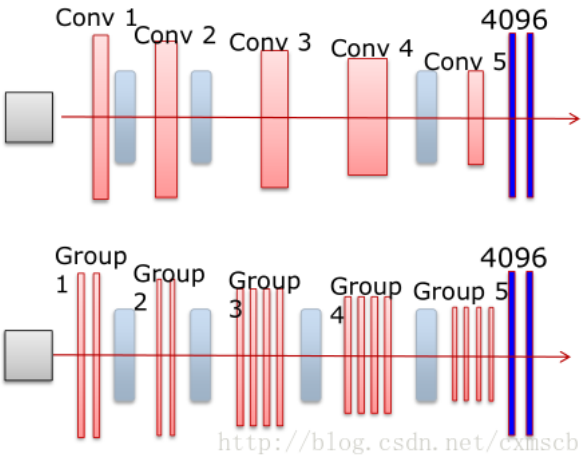

具体参数如图所示：其中CONV3-64：表示卷积核的长和宽为3，个数有64个；POOL2：表示池化窗口的长和宽都为2，其他类似。

```
INPUT: [224x224x3]        memory:  224*224*3=150K   params: 0       (not counting biases)
CONV3-64: [224x224x64]  memory:  224*224*64=3.2M   params: (3*3*3)*64 = 1,728
CONV3-64: [224x224x64]  memory:  224*224*64=3.2M   params: (3*3*64)*64 = 36,864
POOL2: [112x112x64]  memory:  112*112*64=800K   params: 0
CONV3-128: [112x112x128]  memory:  112*112*128=1.6M   params: (3*3*64)*128 = 73,728
CONV3-128: [112x112x128]  memory:  112*112*128=1.6M   params: (3*3*128)*128 = 147,456
POOL2: [56x56x128]  memory:  56*56*128=400K   params: 0
CONV3-256: [56x56x256]  memory:  56*56*256=800K   params: (3*3*128)*256 = 294,912
CONV3-256: [56x56x256]  memory:  56*56*256=800K   params: (3*3*256)*256 = 589,824
CONV3-256: [56x56x256]  memory:  56*56*256=800K   params: (3*3*256)*256 = 589,824
POOL2: [28x28x256]  memory:  28*28*256=200K   params: 0
CONV3-512: [28x28x512]  memory:  28*28*512=400K   params: (3*3*256)*512 = 1,179,648
CONV3-512: [28x28x512]  memory:  28*28*512=400K   params: (3*3*512)*512 = 2,359,296
CONV3-512: [28x28x512]  memory:  28*28*512=400K   params: (3*3*512)*512 = 2,359,296
POOL2: [14x14x512]  memory:  14*14*512=100K   params: 0
CONV3-512: [14x14x512]  memory:  14*14*512=100K   params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512]  memory:  14*14*512=100K   params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512]  memory:  14*14*512=100K   params: (3*3*512)*512 = 2,359,296
POOL2: [7x7x512]  memory:  7*7*512=25K  params: 0
FC: [1x1x4096]  memory:  4096  params: 7*7*512*4096 = 102,760,448
FC: [1x1x4096]  memory:  4096  params: 4096*4096 = 16,777,216
FC: [1x1x1000]  memory:  1000 params: 4096*1000 = 4,096,000
```


GoogleNet 模型

使用了多个不同分辨率的卷积核，最后再对它们得到的feature map 按深度融合在一起，结构如图：

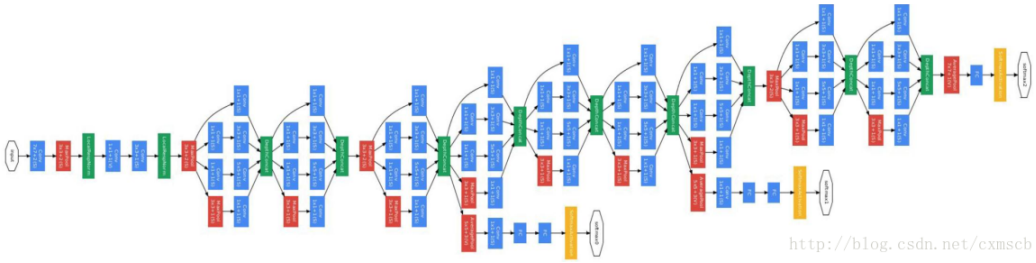

其中，有一些主要的模块称为 Inception module，例如：

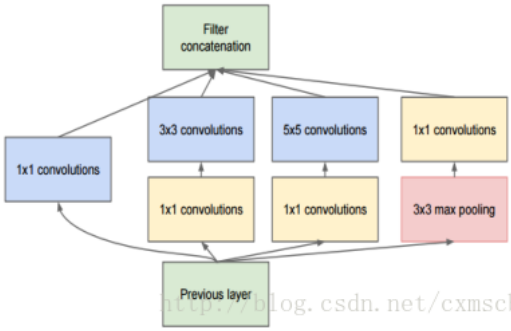

在 Inception module 中使用到了很多 1×1 的卷积核，使用 1×1 的卷积核，步长为1时，输入的feature map和输出的feature map长宽不会发生改变，但可以通过改变 1×1 的卷积核的数目，来达到减小feature map的厚度的效果，从而做到一些训练参数的减少。

GoogleNet还有一个特点就是它是全卷积结构（FCN）的，网络的最后没有使用全连接层，一方面这样可以减少参数的数目，不容易过拟合，一方面也带来了一些空间信息的丢失。代替全连接层的是全局平均池化（Global Average Pooling，GAP）的方法，思想是：为每一个类别输出一个 **feature map**，再取每一个 **feature map** 上的平均值，作为最后的softmax层的输入。

ResNet模型

在前面的CNN模型中，都是将输入一层一层地传递下去（图左），当层次比较深时，模型不是很好训练。在ResNet模型中，它将低层学习到的特征和高层的学习到的特征进行一个融合（加法运算,图右），这样反向传递时，导数传递得更快，减少梯度弥散的现象。

注意：F（X）的shape需要等于 X 的shape ，这样才可以进行相加。

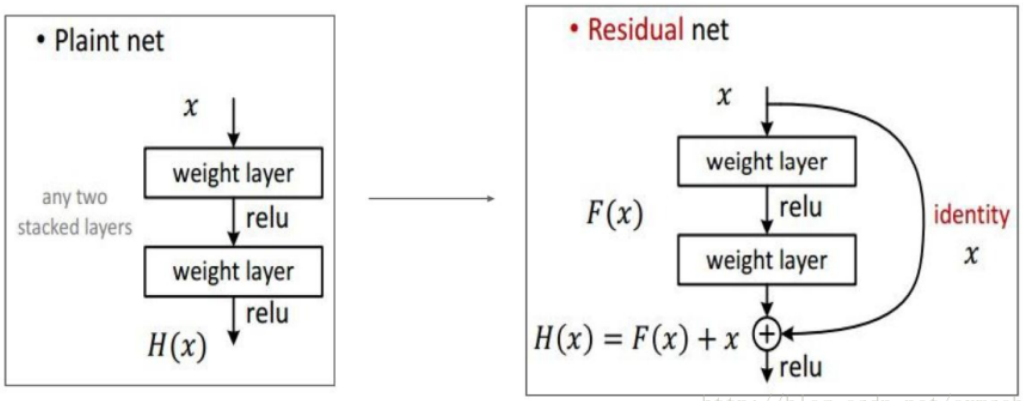

四、Tensorflow代码

主要的函数说明：

> 卷积层：
> tf.nn.conv2d(input, filter, strides, padding, use_cudnn_on_gpu=None, data_format=None, name=None)

参数说明：

- data_format：表示**输入的格式**，有两种分别为：“NHWC”和“NCHW”，默认为“NHWC”
- input：输入是一个**4维格式的（图像）数据**，数据的 shape 由 data_format 决定：当 data_format 为“NHWC”输入数据的shape表示为[batch, in_height, in_width, in_channels]，分别表示训练时一个batch的图片数量、图片高度、 图片宽度、 图像通道数。当 data_format 为“NHWC”输入数据的shape表示为[batch, in_channels， in_height, in_width]
- filter：卷积核是一个**4维格式的数据**：shape表示为：[height,width,in_channels, out_channels]，分别表示卷积核的高、宽、深度（与输入的in_channels应相同）、输出 feature map的个数（即卷积核的个数）。
- strides：表示步长：一个**长度为4的一维列表**，每个元素跟data_format互相对应，表示在data_format每一维上的移动步长。当输入的默认格式为：“NHWC”，则 strides = [batch , in_height , in_width, in_channels] 。其中 batch 和 in_channels 要求一定为**1**，即只能在一个样本的一个通道上的特征图上进行移动，in_height , in_width表示卷积核在特征图的高度和宽度上移动的布长，即 $stride_{height}$ 和 $stride_{width}$ 。
- padding：表示填充方式：“SAME”表示采用填充的方式，简单地理解为以0填充边缘，当stride为1时，输入和输出的维度相同；“VALID”表示采用不填充的方式，多余地进行丢弃。具体公式：

  “SAME”: $output\_spatial\_shape[i] = \lceil (input\_spatial\_shape[i] \,/\, strides[i]) \rceil$

  “VALID”: $output\_spatial\_shape[i] = \lceil ((input\_spatial\_shape[i] - (spatial\_filter\_shape[i] - 1)/strides[i]) \rceil$

> 池化层：
> tf.nn.max_pool(value, ksize,strides,padding,data_format='NHWC',name=None)
> 或者
> tf.nn.avg_pool(...)

参数说明：

- value：表示池化的输入：**一个4维格式的数据**，数据的 shape 由 data_format 决定，默认情况下shape 为[batch, height, width, channels]
- 其他参数与 tf.nn.cov2d 类型
- ksize：表示池化窗口的大小：一个**长度为4的一维列表**，一般为[1, height, width, 1]，因不想在batch和cha

nnels上做池化，则将其值设为1。

> Batch Nomalization层：
> batch_normalization(x,mean,variance,offset,scale, variance_epsilon,name=None)

- mean 和 variance 通过 tf.nn.moments 来进行计算：
  batch_mean, batch_var = tf.nn.moments(x, axes = [0, 1, 2], keep_dims=True)，注意axes的输入。对于以feature map 为维度的全局归一化，若feature map 的shape 为[batch, height, width, depth]，则将axes赋值为[0, 1, 2]
- x 为输入的feature map 四维数据，offset、scale为一维Tensor数据，shape 等于 feature map 的深度depth。

代码示例：

通过搭建卷积神经网络来实现sklearn库中的手写数字识别，搭建的卷积神经网络结构如下图所示：

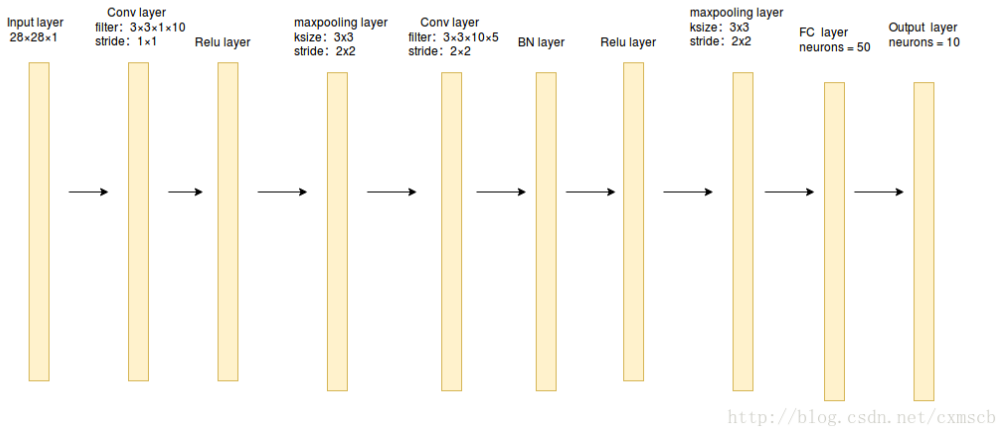


```
import tensorflow as tf
```

```
from sklearn.datasets import load_digits
import numpy as np
```

```
digits = load_digits()
X_data = digits.data.astype(np.float32)
Y_data = digits.target.astype(np.float32).reshape(-1,1)
print X_data.shape
print Y_data.shape
```

```
(1797, 64)
(1797, 1)
```

```
from sklearn.preprocessing import MinMaxScaler
```

```
scaler = MinMaxScaler()
```

```
X_data = scaler.fit_transform(X_data)
```

```
from sklearn.preprocessing import OneHotEncoder
```

```
Y = OneHotEncoder().fit_transform(Y_data).todense() #one-hot编码
```

```
Y
```

```
matrix([[ 1.,  0.,  0., ...,  0.,  0.,  0.],
        [ 0.,  1.,  0., ...,  0.,  0.,  0.],
        [ 0.,  0.,  1., ...,  0.,  0.,  0.],
        ...,
        [ 0.,  0.,  0., ...,  0.,  1.,  0.],
        [ 0.,  0.,  0., ...,  0.,  0.,  1.],
        [ 0.,  0.,  0., ...,  0.,  1.,  0.]])
```

```
# 转换为图片的格式 （batch，height，width，channels）
X = X_data.reshape(-1,8,8,1)
```

```
batch_size = 8 # 使用MBGD算法，设定batch_size为8
```

```
def generatebatch(X,Y,n_examples, batch_size):
    for batch_i in range(n_examples // batch_size):
        start = batch_i*batch_size
        end = start + batch_size
        batch_xs = X[start:end]
        batch_ys = Y[start:end]
        yield batch_xs, batch_ys # 生成每一个batch
```

```
tf.reset_default_graph()
# 输入层
tf_X = tf.placeholder(tf.float32,[None,8,8,1])
tf_Y = tf.placeholder(tf.float32,[None,10])
```

```
# 卷积层+激活层
conv_filter_w1 = tf.Variable(tf.random_normal([3, 3, 1, 10]))
conv_filter_b1 =  tf.Variable(tf.random_normal([10]))
relu_feature_maps1 = tf.nn.relu(\
                tf.nn.conv2d(tf_X, conv_filter_w1,strides=[1, 1, 1, 1], padding='SAME') + co
```

```
# 池化层
max_pool1 = tf.nn.max_pool(relu_feature_maps1,ksize=[1,3,3,1],strides=[1,2,2,1],padding='SAM
```

```
print max_pool1
```

```
Tensor("MaxPool:0", shape=(?, 4, 4, 10), dtype=float32)
```

```
# 卷积层
conv_filter_w2 = tf.Variable(tf.random_normal([3, 3, 10, 5]))
conv_filter_b2 =  tf.Variable(tf.random_normal([5]))
conv_out2 = tf.nn.conv2d(relu_feature_maps1, conv_filter_w2,strides=[1, 2, 2, 1], padding='S
print conv_out2
```

```
Tensor("add_4:0", shape=(?, 4, 4, 5), dtype=float32)
```

```
# BN归一化层+激活层
batch_mean, batch_var = tf.nn.moments(conv_out2, [0, 1, 2], keep_dims=True)
shift = tf.Variable(tf.zeros([5]))
scale = tf.Variable(tf.ones([5]))
epsilon = 1e-3
BN_out = tf.nn.batch_normalization(conv_out2, batch_mean, batch_var, shift, scale, epsilon)
print BN_out
relu_BN_maps2 = tf.nn.relu(BN_out)
```

```
Tensor("batchnorm/add_1:0", shape=(?, 4, 4, 5), dtype=float32)
```

```
# 池化层
```

```
max_pool2 = tf.nn.max_pool(relu_BN_maps2,ksize=[1,3,3,1],strides=[1,2,2,1],padding='SAME')
```

```
print max_pool2
```

```
Tensor("MaxPool_1:0", shape=(?, 2, 2, 5), dtype=float32)
```

```
# 将特征图进行展开
max_pool2_flat = tf.reshape(max_pool2, [-1, 2*2*5])
```

```
# 全连接层
fc_w1 = tf.Variable(tf.random_normal([2*2*5,50]))
fc_b1 =  tf.Variable(tf.random_normal([50]))
fc_out1 = tf.nn.relu(tf.matmul(max_pool2_flat, fc_w1) + fc_b1)
```

```
# 输出层
out_w1 = tf.Variable(tf.random_normal([50,10]))
out_b1 = tf.Variable(tf.random_normal([10]))
pred = tf.nn.softmax(tf.matmul(fc_out1,out_w1)+out_b1)
```

```
loss = -tf.reduce_mean(tf_Y*tf.log(tf.clip_by_value(pred,1e-11,1.0)))
```

```
train_step = tf.train.AdamOptimizer(1e-3).minimize(loss)
```

```
y_pred = tf.arg_max(pred,1)
bool_pred = tf.equal(tf.arg_max(tf_Y,1),y_pred)
```

```
accuracy = tf.reduce_mean(tf.cast(bool_pred,tf.float32)) # 准确率
```

```
with tf.Session() as sess:
    sess.run(tf.global_variables_initializer())
    for epoch in range(1000): # 迭代1000个周期
        for batch_xs,batch_ys in generatebatch(X,Y,Y.shape[0],batch_size): # 每个周期进行MBGD
            sess.run(train_step,feed_dict={tf_X:batch_xs,tf_Y:batch_ys})
        if(epoch%100==0):
            res = sess.run(accuracy,feed_dict={tf_X:X,tf_Y:Y})
            print (epoch,res)
    res_ypred = y_pred.eval(feed_dict={tf_X:X,tf_Y:Y}).flatten() # 只能预测一批样本，不能预测一
    print res_ypred
```

```
(0, 0.36338341)
(100, 0.96828049)
(200, 0.99666113)
(300, 0.99554813)
(400, 0.99888706)
(500, 0.99777406)
(600, 0.9961046)
(700, 0.99666113)
(800, 0.99499166)
(900, 0.99888706)
[0 1 2 ..., 8 9 8]
```

在第100次个batch size 迭代时，准确率就快速接近收敛了，这得归功于Batch Normalization 的作用！需要注意的是，这个模型还不能用来预测单个样本，因为在进行BN层计算时，单个样本的均值和方差都为0，会得到相反的预测效果，解决方法详见归一化层。

```
from sklearn.metrics import  accuracy_score
```

```
print accuracy_score(Y_data,res_ypred.reshape(-1,1))
```

```
0.998887033945
```

本文已收录于以下专栏：机器学习

目前您尚未登录，请 登录 或 注册 后进行评论

xbutterflyx 2018-03-27 15:25 #14楼 回复

看的很明白,谢谢博主!!收藏好评!

cz_bykz 2018-03-09 22:56 #13楼 回复

清晰易懂，楼主讲解的很好，大有收获！

cm_sunshine 2018-02-28 18:09 #12楼 回复

感谢博主，思路清晰，通俗易懂， 点赞

查看 17 条热评

Deep Learning模型之：CNN卷积神经网络（一）深度解析CNN

http://m.blog.csdn.net/blog/wu010555688/24487301 本文整理了网上几位大牛的博客，详细地讲解了CNN的基础结构与核心思想，欢迎交流。 [1...

u012641018 2016年08月18日 10:11 6855

转载——卷积神经网络(CNN)基础入门介绍

Chrls_Wang 2016年06月18日 16:15 10162

该篇写得很详细并且很清楚，转自：http://www.jeyzhang.com/cnn-learning-notes-1.html 概述 卷积神经网络(Convolutional Neur...

详解卷积神经网络(CNN)

qq_25762497 2016年04月04日 00:02 34276

卷积神经网络（Convolutional Neural Network, CNN）是一种前馈神经网络，它的人工神经元可以响应一部分覆盖范围内的周围单元，对于大型图像处理有出色表现。...

CNN笔记：通俗理解卷积神经网络

v_JULY_v 2016年07月02日 22:14 130530

通俗理解卷积神经网络（cs231n与5月dl班课程笔记）1 前言 2012年我在北京组织过8期machine learning读书会，那时“机器学习”非常火，很多人都对其抱有巨大的热情。当我20...

深度学习（DL）：卷积神经网络（CNN）：从原理到实现

序深度学习现在大火，虽然自己上过深度学习课程、用过keras做过一些实验，始终觉得理解不透彻。最近仔细学习前辈和学者的著作，感谢他们的无私奉献，整理得到本文，共勉。1.前言 （1）神经网络的缺陷在神经网...

a819825294 2016年12月01日 20:30 20959

CNN笔记：通俗理解卷积神经网络

Real_Myth 2016年07月04日 22:17 18125

通俗理解卷积神经网络（cs231n与5月dl班课程笔记） http://blog.csdn.net/v_july_v/article/details/51812459 ...

Deep Learning（深度学习）学习笔记整理系列之（七）

Deep Learning（深度学习）学习笔记整理系列 zouxy09@qq.com http://blog.csdn.net/zouxy09 作者：Zouxy version 1.0 201..

.

zouxy09 2013年04月10日 10:48 540194

深度学习Deep Learning（01）_CNN卷积神经网络

深度学习 Deep Learning github地址：https://github.com/lawlite19/DeepLearning_Python 有关神经网络的部分可以查看这里的BP神经网络的...

u013082989 2016年12月15日 17:49 9512

深度学习笔记五：卷积神经网络CNN(基本理论)

xierhacker 2016年12月29日 15:49 6069

卷积神经网络基本理论

CNN 卷积神经网络结构

zhongkeli 2016年07月07日 22:02 17117

CNNcnn每一层会输出多个feature map, 每个Feature Map通过一种卷积滤波器提取输入的一种特征，每个feature map由多个神经元组成，假如某个feature map的sha...

码农怎能不懂英语？！试试这个数学公式

老司机教你一个数学公式秒懂天下英语

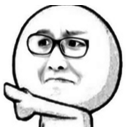

卷积神经网络CNN原理以及TensorFlow实现

xukaiwen_2016 2017年04月27日 23:10 18866

在知乎上看到一段介绍卷积神经网络的文章，感觉讲的特别直观明了，我整理了一下。首先介绍原理部分。 通过一个图像分类问题介绍卷积神经网络是如何工作的。下面是卷积神经网络判断一个图片是否包...

CNN(卷积神经网络)概述

laingliang 2016年11月07日 22:28 8171

过去几年，深度学习（Deep learning）在解决诸如视觉识别(visual recognition)、语音识别(speech recognition)和自然语言处理(natural langua...

卷积神经网络（Convolutional Neural Networks，简称CNN）

卷积神经网络（CNN）算是深度神经网的前身了，在手写数字识别上在90年代初就已经达到了商用的程度。先明确一点就是，Deep Learning是全部深度学习算法的总称，CNN是深度学习算法在图像处理领域...

Before1993 2016年04月25日 08:39 1886

Deep Learning论文笔记之（四）CNN卷积神经网络推导和实现

Deep Learning论文笔记之（四）CNN卷积神经网络推导和实现zouxy09@qq.comhttp://blog.csdn.net/zouxy09 自己平时看了一些论文，但老...

zouxy09 2013年08月16日 00:40 387472

【目标检测】RCNN算法详解

shenxiaolu1984 2016年04月05日 23:10 88403

深度学习用于目标检测的RCNN算法

思考卷积神经网络（CNN）中各种意义

aimreant 2016年11月13日 00:24 5550

思考卷积神经网络（CNN）中各种意义只是知道CNN是不够，我们需要对其
进行解剖，继而分析不同部件存在的意义CNN的目的简单来说，CNN的目的是以一定的模型对事物进行特征提取，而后根据特征对该事物进行分...

Deep Learning-TensorFlow (1) CNN卷积神经网络_MNIST手写数字识别代码实现详解

import tensorflow as tf import tensorflow.examples.tutorials.mnist.input_data as input_data import...

CZ626626 2017年03月19日 12:53 2315

深度学习与卷积神经网络（直观理解）

u014696921 2016年12月16日 20:45 4122

好吧，读了男神哥哥们的博客，自己写不来更好的。 附上链接： 凌风
探梅的卷积神经网络（CNN）新手指南 http://blog.csdn.NET/real_myth/article/...

卷积神经网络CNN原理——结合实例matlab实现

u010540396 2016年10月22日 21:32 29058

卷积神经网络CNN是深度学习的一个重要组成部分，由于其优异的学
习性能（尤其是对图片的识别）。近年来研究异常火爆，出现了很多模型LeNet、Alex net、ZF net等等。由于大多高校在校生使用ma...

吴恩达《深度学习-卷积神经网络》1--卷积神经网络

1. Computer Vision计算机视觉包括： --图片分类（图片识别）Image classification --目标检测 object detection --神经风格迁移 neur...

weixin_41043240 2018年02月19日 21:07 189